《数据安全系统设计与实践》课程项目说明

项目背景

本课设定华辰设备制造有限公司来自中国，德维工业服务有限公司来自德国。公司所属国家与每台设备的实际所在地是两回事，设备所在地以表内记录为准。

华辰设备制造有限公司希望提前发现故障，德维工业服务有限公司希望安排维修并复核停机。要把这两个目标变成可计算的问题，本项目安排了三项德维数据使用需求：服务分析人员需要关联同一设备的维修案例，研究组需要分析型号、区域和运行情况与故障的关系，管理人员需要确认故障案例数和平均停机时长。

双方还希望按统一口径汇总告警，并比较联合训练能否帮助预测后续故障。两方数据包含共同设备，开展这两项联合分析前必须先完成共同设备匹配。因此，本项目形成三项德维数据用途，以及共同设备匹配、联合告警统计、联合故障模型，共六项用途。匹配结果供后续计算使用，并非六项都是给最终使用者的报告；六项的划分是本项目的安排，不是通用分类标准。

这些需要不能靠直接转交原表完成：非法时长会影响计算，完整原表包含超出使用者需要的信息，共同设备还可能重复计数。五个任务因此分别处理数据是否可用、用途边界、具体处理及结果与过程核查。全部数据为合成数据，程序在本地运行，没有真实多方隔离；文中的“正式发布”指按本课用途规则生成本地结果文件，不表示已经向外部机构发送数据。

数据关系与任务交接

华辰持有`数据集/华辰设备制造有限公司/cn_devices.csv`（华辰设备表）；德维持有`数据集/德维工业服务有限公司/de_devices.csv`（德维设备表）和同目录的`service_cases.csv`（服务案例表）。目录表示数据持有方，设备实际所在地以`site_country`为准。

设备表每台设备一条业务记录，案例表每次维修或检查事件一条业务记录；原始输入含待处理的重复行。同一设备可以有多条案例，三表通过`device_id`关联，案例通过`case_id`区分。双方只持有部分共同设备，案例只覆盖部分设备，没有案例不等于没有故障。输入行已打乱，关联依靠编号，不依靠行位置。

本课用2026年3月的运行信息预测随后90天是否发生故障。90天是给定预测窗口，未来故障标签是事后结果，可用于训练和评价，不能用于修复前面的运行指标或作为预测输入。

任务	为什么在这里做	得到什么，交给谁
任务1：治理与盘点	先判断数值能否用于计算、字段包含什么信息	清洗表供后续计算，字段分级供任务2设计规则，处理证据供回查
任务2：用途决策	同一数据的不同使用者需要不同输入与输出边界	六项规则交给任务3、4执行，交给任务5核验
任务3：共享与发布	按德维的三项需求生成不同形式的结果	内部分析、研究数据、服务统计及处理证据交给任务5
任务4：联合分析	先处理共同设备，再汇总告警并比较模型	匹配结果、联合告警统计、模型参数及比较证据交给任务5
任务5：使用与追踪	文件已生成，还要核对用途、来源对应与实际操作	结果检查、审计链验证与链内事件查询，支持最终报告的结论

依赖为**任务1 → 任务2 →（任务3、任务4分别开展）→ 任务5**。任务3、4都读取任务1、2的结果，两者没有先后依赖。为让两条联合计算使用同一去重口径，本课约定共同设备由德维贡献一次；任务1的共同参考也采用这一约定，具体原因见任务1、4。所有后续步骤使用同一次运行的前序结果，修改前序程序后须重新运行受影响流程。

任务5先核对业务结果，再检查保存后读回的审计链，最后查询通过检查的链内事件。三张结论表为`结果检查.csv`、`审计链验证.csv`和`操作查询.csv`，操作明细用于回查，完整链及区块概览位于任务5输出的`辅助材料/`；各文件读法见任务5背景。

运行

使用Python 3.10及以上版本。

在本文件所在的项目根目录执行：

```
python -m pip install -r requirements.txt
python main.py
```

根入口`main.py`先说明合作需求和任务交接，再显式执行五个业务阶段。运行时分别展示业务依赖与本次执行顺序，每个阶段说明实际产出及其去向，结束时汇总六项用途的状态。任务3、4是两个业务分支，程序按顺序运行。

指定任务及必要前置步骤使用`python main.py --task 4`，此时只运行任务1、2、4；也可进入任务目录执行`python main.py`，由根入口准备同一次运行和必要前序。任务目录入口固定运行当前任务，也支持`--output-dir`、`--verbose`和`--help`；相对输出路径以启动时的工作目录为基准。完整运行使用`python main.py`或`python main.py --task 5`。默认终端显示简短阶段摘要；加上`--verbose`可在各阶段结束后回显完整日志，例如`python main.py --task 4 --verbose`。

每次结果保存到新的`runs/RUN-.../`，也可用`--output-dir 新目录`指定本次目录，已有目录不会被覆盖。先打开`项目运行概览.md`，确认本次范围、阶段执行情况与六项用途状态，再按概览中的文件路径查看`结果索引.csv`和具体任务证据。完整阶段输出保存在`运行日志/任务目录名.log`，例如`运行日志/04_跨机构联合分析.log`；出现异常时查看`错误日志.txt`及对应阶段日志。目录名末尾的`Z`表示UTC时间，`run.json`记录带时区的实际启动与结束时间；它们与2026年3月的业务观察期不同。逐个单独运行任务会分别建立运行目录；完整项目报告应引用最后一次完整运行。依赖范围见`requirements.txt`。随工程保留的旧运行目录只供了解初始输出，不代表本组本次结果；旧数据版本的结果也不能与本次运行混用。

未完成作答时仍可运行并生成“普通基线”：保留尚未完成保护的本地结果，帮助观察程序结构，不能当作合格发布。后文的“比较基线”则指匿名方案或模型评价中的参照方案，用来比较效果；两者含义不同。未完成、检查失败与真实空结果分别表示。若任务1仍有非法时长，受影响的匿名比较、停机均值和模型训练明确等待数据治理，不将缺失当零或跳过记录计算；完成前序任务后重新运行。部分无效配置会登记未就绪并使用基线，违反校验约束的结果会报错或标为检查失败，应结合原因判断。基线中的原标识和精确统计仅供本地课堂观察。

概览将本次范围、阶段执行和业务状态分开：未选用途标为“本次未选择”，计划中因异常未启动的阶段说明停止原因；它们不等同于基线或检查失败。只运行任务1、2时重点查看治理和规则，尚未安排六项业务结果的生成；运行任务3或4后未执行任务5的结果仍需核验。概览分别显示业务检查、原链验证和查询状态，不计算作业完成率。14-A未完成时全部正式查询等待验链，次数留空，不能据此判定13-A/B未填写；完成验链和事件核对后，才根据查询作答生成实际计数。题号不变，实际执行先14后13。

结果状态按实际步骤区分：

输出状态	含义与下一步
等待任务1数据治理	计算所需数值仍有非法值；完成任务1并重新运行受影响流程
仅基线，保护未完成	规则或保护作答未完成；检查对应题号及处理说明
检查失败	已执行的配置、结果或来源核验不符合要求；根据原因修正后重跑
已保存	本阶段已保存结果，仍需任务5核验
检查通过	已通过本项目的实际结果检查，仍需结合代码和报告判断作业完成度

等待治理会同时反映在相关比较表、结果索引与运行提示中。未扫描、尚未实现和真实空结果按各表的具体状态判断；空列表、零计数或缺失指标不能脱离状态解释。

作答

共14道代码题、27处作答框，每题子框从A顺序排列。先读项目与任务背景了解用途和任务关系，再按题号定位各任务`main.py`中的作答区，阅读框旁的题目、输入输出约束与提示。需要变量或调用上下文时再查`main()`和紧邻函数，遇到不熟悉的参数再查辅助函数和方法示例。

任务1的联系信息与邮编规范化直接在`main()`的TODO01填写。校验、本地训练、文件读写和摘要计算等功能已提供，需要查阅时可按下表定位：

任务	同目录辅助文件	已提供的功能
任务1	`quality_support.py`	日期核对、共同参考、质量证据、字段分级与资产核对（由主流程保存）
任务2	无	用途配置与规则整理集中在`main.py`
任务3	`release_support.py`	匿名配置及转换独立校验、方案比较、统计检查与发布
任务4	`analysis_support.py`	训练数据准备、共同记录与归属核验、模型比较与检查表保存
任务5	`result_checks.py`、`audit_support.py`	实际结果与来源核验、审计链读回与事件定位、审计变化样例

`utils.py`提供运行组织、阶段日志、索引和概览等公共功能。`prepare_task_run`准备本次任务及必要前置步骤；`save_and_register_result`保存业务结果并记录规则、来源与处理状态。具体读写、翻译和摘要计算无需重写。辅助文件与入口一起运行，提交时一并保留；算法目录提供独立方法示例。

任务	题号	作答框	主要工作
任务1：数据资产盘点与质量治理	01—03	6	联系信息与邮编规范化、数值治理、备注扫描
任务2：数据流转分析与使用决策	04—05	6	用途字段、来源分级核对与保护决策

任务	题号	作答框	主要工作
任务3：数据共享与安全发布	06—08	6	假名化、匿名配置及泛化抑制、统计发布
任务4：跨机构联合分析	09—11	5	匹配及共同记录核对、贡献求和、联邦加权聚合
任务5：数据使用管理与过程追踪	12—14	4	来源重建与核验、自主查询、审计链核对

11-A的逐轮聚合由`main.py`中的作答函数完成，其返回值在任务4算法目录的`fedavg_logistic.py`中独立核验。

返回值须按各题接口区分：04-D未填返回`None`，核对无问题返回`[]`；12-A填写`records_ok`布尔判断；14-A完成时返回`(布尔判断, 原因)`，未填返回`None`。

基础任务在同编号“作答区 开始／结束”之间填写实现或配置；选择算法后，在对应作答框内导入实际调用的方法；文件顶部仅保留框架已使用的导入。保留字典键名和框外流程，其他`None`可能是运行状态。回调参数需要适配时可在框内定义普通函数；函数名表示函数对象，加括号则立即调用。08-A选择发布机制后，框架自动确定发布函数。基础任务只要求在成对边框内作答。完成基础内容后，自主拓展可以修改框外程序、辅助文件或新增展示功能；须说明改动位置和理由，保留原始数据、基本业务要求、可运行入口和可核验结果。

02、03、07、08、09各选一条合格路线即可；13自主设计真实事件查询，其余为核心接入。方法位置与选择限制见对应任务背景。示例使用独立小数据，可单独运行，需按题目接口适配。

策略理由、推导和结果分析写入任务报告。05-A/B的方法理由及13-A的查询问题会进入程序输出，仍需在代码中填写；模型本地更新、查询事件来源范围和格式预检查已提供；11-A完成实际逐轮聚合，14-A完成链的编号、链接及摘要核对。报告可直接引用已有理由和查询结果，不重复抄写。程序退出成功不等于作业完成，应结合结果状态、失败原因、实际实现和报告证据判断。

提示

以下建议用于帮助理解和完成项目，按需采用，不增加必交材料。

1. **用注释说明队伍的分析思路。** 在关键处理或判断旁，说明为什么这样做、依据是什么、可能有什么局限，不必逐行翻译代码。
2. **梳理项目的数据链路。** 追踪原始表如何经过清洗、用途规则、共享或联合分析，最终进入结果核验。可以绘制数据流转图，标明各步骤读取和生成的文件。
3. **梳理每个任务的函数调用关系。** 从 `main()` 出发，找出调用了哪些函数、传入什么、返回什么，以及返回结果如何继续使用。关系较复杂时，可以画简要调用图。
4. **结合实际记录理解处理效果。** 选取一个设备或案例，按业务编号对照处理前后的值和质量记录，判断程序是否实现了队伍的处理意图，避免只看运行是否报错。
5. **分步完成，及时验证。** 每完成一处作答，先运行对应任务并查看相关输出；修改前序任务后，重新运行依赖它的任务。完整流程的结论引用同一次运行的证据，区分未完成、未命中和检查通过等状态；改进前后比较可引用两次运行，但须分别注明版本、配置和运行目录。

6. **理解并用好项目的自由度。** 本项目允许在各题规定范围内选择或自行实现方法，设计识别规则、匿名化配置和操作查询。本项目不限定唯一实现；不同方案只要满足接口、数据与输出约束，并能用实际结果解释选择及局限，都可以成立。保留原始数据和题目明确给定的条件，每道选法题完成一条合格路线即可。完成基础任务后，还可自主完善程序、分析或成果展示，具体见下方“总项目完成、改进与展示要求”。

提交

每完成一个任务，提交完成后的对应任务文件夹和一份任务报告。任务文件夹保留完成后的`main.py`、同目录辅助`.py`、算法文件及原有材料，并附本任务报告引用的结果副本，注明其原运行目录。这里的任务文件夹指下表中的源码文件夹，不是`runs/`中的任务输出目录；公共程序和前置依赖仍使用项目原结构，阶段提交不要求把单个任务改成独立工程。

所有报告文件名必须包含队长姓名和队长学号。提交时将下列名称中的“队长姓名”和“队长学号”替换为本队伍的实际信息，并保留下划线分隔格式。

提交阶段	提交内容
任务1	`01_数据资产盘点与质量治理/和任务一_队长姓名_队长学号.docx`
任务2	`02_数据流转分析与使用决策/和任务二_队长姓名_队长学号.docx`
任务3	`03_数据共享与安全发布/和任务三_队长姓名_队长学号.docx`
任务4	`04_跨机构联合分析/和任务四_队长姓名_队长学号.docx`
任务5	`05_数据使用管理与过程追踪/和任务五_队长姓名_队长学号.docx`
总项目	完整的学生版工程（含五份任务报告）和项目报告_队长姓名_队长学号.docx

前五行分别对应任务阶段提交，第六行为全部任务完成后的总项目提交。总项目保留队伍完成的学生版工程，包括根入口`main.py`、`utils.py`、五个任务文件夹、三张输入CSV、`requirements.txt`、`实验报告模板.docx`及报告引用的运行结果；五份任务报告随相应任务材料保留，另附一份串联整体工作的项目报告。

总项目完成、改进与展示要求

1. **完成基础内容。** 完成前五个任务的规定作答、五份任务报告和项目报告，运行完整流程，并能够结合实际结果说明各任务的作用、衔接关系和主要结论。尚未完成或检查失败的部分，应如实说明原因及影响。
2. **开展自主检查与改进。** 在完成基础内容后，鼓励各组检查项目是否存在程序错误、文档表述不清、使用不便或方法上的不足，选择有价值的方向进行完善。可以修复问题、优化处理方法、补充分析功能，也可以改善结果展示。说明发现了什么问题、具体修改了哪些地方，以及用什么证据验证效果。不要求每组必须发现程序错误，尚未实施的想法作为改进建议说明。
3. **提高成果的可展示性。** 鼓励各组把关键过程、结果和改进效果整理成便于理解的展示。例如，用流程图说明五个任务如何衔接，用图表呈现数据治理或方案比较结果，用清晰的页面、查询功能或操作演示帮助查看项目输出。展示应让听众容易理解：项目解决了什么问题、得到了什么结果、本组做出了哪些选择和改进。展示内容应对应真实运行结果，并能回查相关证据；具体形式由各组选择。

4. **完成最终提交与汇报。** 提交完整工程、五份任务报告和项目报告；自主增加的程序、展示材料及必要的使用说明随工程一并提交。在项目报告中说明已实施的改进、实际效果和局限。小组汇报先简要交代基础任务完成情况，再选取有代表性的结果进行展示；有自主改进时，重点讲清楚改进前后的差别及其价值。

报告说明

五份任务报告和一份项目报告统一使用`实验报告模板.docx`，分别复制模板填写，封面“实验名称”填写对应任务名称或总项目名称。正文均按模板的“方案分析、方案设计、实验结果、实验总结”组织：任务报告分析本任务的方法与结果，项目报告说明各任务之间的联系和整体结论，可引用任务报告中已有的分析，不必重复抄写。已实施的改进方法写入“方案设计”，验证效果与展示写入“实验结果”，局限及后续建议写入“实验总结”，无需另交一份改进报告。

报告注明本次运行目录，引用可定位的真实文件、记录或指标，解释选择依据与局限。未测量的比较写成原理或适用条件分析，不能当作实测；未完成时如实说明基线和缺少的证据。

（要求：报告应注重体现队伍对问题、方法、过程与结果的理解和思考，避免简单罗列内容；同时注意结构清晰、逻辑连贯、表达易读。能够充分体现队伍分析、判断与总结的内容，将获得更高评价。）