任务1：数据资产盘点与质量治理

任务背景与目标

华辰设备制造有限公司负责设备制造并维护设备档案，希望利用运行数据提前发现故障；德维工业服务有限公司承担维修服务，希望安排维修、复核停机并了解服务效果。双方准备合作分析：华辰提供设备表`cn_devices.csv`，德维提供设备表`de_devices.csv`和服务案例表`service_cases.csv`。两方设备表有共同设备，一台设备也可能对应多条服务案例。要让这些材料支持后续研究、服务统计和联合故障预测，既要弄清各表记录什么、如何关联，也要处理影响计算的质量问题，并识别其中的联系信息。你从本任务开始承担数据整理工作，为后续按用途使用数据准备可回查的基础。

接收数据后，团队发现运行时长和停机时长含有负数、无法解析的文本或无穷值，姓名、邮箱、电话和邮编的格式也不一致。服务统计要计算停机均值，故障模型要读取运行时长，这些问题必须先处理。但“数值很大”不等于录错：德维维修主管指出，设备等待备件可能确实停机很久。因此，需要依据字段含义区分非法值与合法的特殊情况，保留修改和待核实证据。

修好数值还不足以决定怎样使用数据。一条格式正确的邮箱仍能联系到对象，一条合法停机记录仍是需要限定用途的业务信息。维修备注是自由文本，仅看列名不知道其中是否夹带联系方式，所以还要扫描实际内容、复核字段分级。**质量判断回答“值能否这样用于计算”，保护判断回答“信息能以什么方式交给什么用途”。** 后一个问题还需任务2结合使用需要继续判断，分级较高不等于一律禁止所有计算。

本任务交付三张清洗表、字段分级与处理证据。日期核对、基础分级和证据保存已提供，你需要完成联系信息与邮编规范化、数值治理选择和备注扫描三道题；后续任务从这些结果继续，不直接修改原始CSV。

输入与程序起点

三张原表都位于当前版本根目录的`数据集/`，目录表示持有方，设备所在地以行内`site_country`为准：

原始文件	一条业务记录表示什么	需要处理的字段
`数据集/华辰设备制造有限公司/cn_devices.csv`	华辰持有的一台设备	`operating_hours`、`contact_name`、`contact_email`、`contact_phone`、`site_postcode`
`数据集/德维工业服务有限公司/de_devices.csv`	德维持有的一台设备，与华辰表可能重叠	与华辰设备表相同
`数据集/德维工业服务有限公司/service_cases.csv`	一次服务案例，同设备可以有多次案例	`downtime_hours`、`service_note`、联系人和工程师的姓名/邮箱/电话、`site_postcode`

已提供的步骤包括：删除整行完全相同的重复记录；核对案例关闭日期；将缺失温度暂估为20 °C；建立基础字段分类和资产盘点。这里的去重不负责合并同一业务编号下内容不同的记录。

初始程序中，数值方法未接入或TODO01保留`pass`时，对应原值不变，未处理问题进入质量记录；扫描回调或必做文本规则未填时显示未扫描，备注分级相应尚未完成。三张处理表与证据文件仍会生成，文件名中的“清洗”不表示全部质量问题已经处理。

按`main()` → TODO01—03 → 所需方法示例阅读，数值治理、扫描与分类示例在`可选算法/`。

同目录的`quality_support.py`提供日期核对、共同参考统计、修复结果校验、字段分级、资产盘点与质量证据处理。01-A/B位于`main()`处理三张表的循环中，在建立共同参考前执行；02-A/B选择时长修复回调，`scan_service_notes(cases)`执行03-A/B扫描。

输入记录的行顺序已打乱，按业务编号关联和定位，不依赖表内顺序或表尾位置判断异常。设备以`device_id`关联，案例以`case_id`区分；同一设备可以有多条案例。设备的三个运行指标均统计同一个月：`temperature_c`是平均环境温度，`operating_hours`是累计运行小时，`alarm_count`是累计告警次数。

本题统计月份为2026年3月，共31天，按每天24小时计，**整月运行时长最多为31 × 24 = 744小时**。这是合法上限，不是每台设备都应达到的运行时长。运行时长0和744本身均合法。时长字段可能含缺失、文本或非有限表示，应按完整数值约束判断，不能只匹配某个固定错误值。

`failure_next_90d`表示随后90天是否发生故障，是事后得到的标签，不能用于修复前面的运行指标。服务案例记录维修和检查事件，`confirmed_failure`表示本次是否确认故障，`downtime_hours`表示本次停机小时；案例停机时长没有给定的真实上界。

姓名、邮箱、电话和邮编均按文本读取；即使整列缺失，也能使用字符串处理接口。电话保留国际号码加号，邮编保留前导零；姓名可能重复，联系人按`contact_employee_id`区分。未关闭案例可以缺少`closed_date`；已填写的关闭日期若无法解析或早于创建日期，已提供逻辑会置空并登记待复核。该步骤只核对关闭日期，不是对所有日期字段的全面治理；缺失地址不能编造。设备所在地以`site_country`为准，联系人允许跨城市支援，不应仅凭联系人与站点城市不同判错。

共同参考与修复边界

共同设备还带来一个修复问题：假设同一设备在两方表中的时长都缺失，双方各用本地中位数修复，可能得到不同值；任务4再联合使用时就出现冲突。本任务因此先核对共同设备的基础记录，再建立共同参考。两方设备共用同一修复方法和参数；选择分组中位数时使用这份共同参考，避免因各自估计而产生差异。修复后的一致值仍是估计，不能当成真实观测。

固定替代与分组中位数都必须处理全部非法值，不能将“是否截到上界”理解为可以保留超过744小时的运行时长。两张设备表共用同一替代规则和参数；停机的合法范围不设上界，72小时只用于后续统计贡献。固定替代可不使用分组中位数，但仍需满足相同质量约束。

按型号分组运行时长、按国家分组案例停机，是本课提供的两个参考统计口径：设备与案例是不同业务单位，分别组织参考，不能混在一起求替代值。组内至少3条是本课设定的最低参考数量，用来决定是否改用全局统计，与任务3匿名化的k=3含义不同。共同设备按德维（DE）记录计一次，只是和任务4统一的去重约定，不表示其信息更可信。

框架先对三张表建立基础格式快照，再统一准备参考统计：运行时长使用去重设备，共同设备按既定DE归属只计一次、按型号分组；停机时长使用去重案例、按国家分组，不能混合两个业务单位。只纳入合法观测，组内不足3条时用同一全局中位数，全局也为空时使用已给定的共同固定回退。**分组中位数路径不使用未来故障标签，也不能换成本地统计或修复后的统计。** 参考建立前会检查设备及案例编号；编号缺失、同编号下有冲突记录，或两方共同设备的基础记录不一致时会报错，不能靠估计覆盖冲突。框架保留实际修改和复核记录，估计值不能当作真实观测。

需要完成的作答

TODO01【核心填空与接入】联系信息与邮编规范化

直接在`main()`中填写01-A、01-B，依次处理`cn_devices.csv`、`de_devices.csv`和`service_cases.csv`。01-A对已有姓名列去首尾空白、邮箱列去首尾空白并转小写、电话列去空白与括号及连字符；规范后仍不符合本课格式的邮箱和电话置空待核实。01-B去除邮编首尾空白，按同一行`site_country`检查CN为6位、DE为5位数字，不合格时置空。电话和邮编保留字符串、加号和前导零；保留原索引、行和其他字段，不改维修备注，不编造缺失资料。

TODO02【选法与方案设计】数值治理

02-A在`choose_hours_repair()`中为`cn_devices.csv`和`de_devices.csv`的`operating_hours`接入共用修复回调；02-B在`choose_downtime_repair()`中为`service_cases.csv`的`downtime_hours`接入修复回调。选择固定替代或共同分组中位数路径，选择依据写入报告。两类数值均须有限、非负，运行时长不超过744小时；只修复非法值，保留原索引、字段、行顺序和合法长停机。

TODO03【选法与方案设计】维修备注识别

只扫描`service_cases.csv`的`service_note`，`patterns`不用于另外两张设备表，也不修改结构化联系信息列。03-A选择原文扫描或规范化副本扫描回调，03-B在已给基础EMAIL规则上补齐PHONE规则，可按所选扫描方式调整，范围与取舍写入报告。扫描回调每次接收`(text, patterns)`，返回当前规则中的、不重复的线索名称列表；框架再汇总为逐案例线索表，用`case_id`定位实际案例，不修改原备注。缺少方法或必做EMAIL、PHONE规则仍为None表示未扫描，返回空列表才是已扫描未命中。EMPLOYEE、LOCATION、NAMED_CONTACT已预留为选做规则，保留None时跳过。

方法参考与约束

TODO01针对结构化列：姓名为`contact_name`、`engineer_name`，邮箱为`contact_email`、`engineer_email`，电话为`contact_phone`、`engineer_phone`，邮编为`site_postcode`；当前表没有的列跳过。邮箱要求非空用户名与域名、恰好一个`@`、无空白且以`.invalid`结尾；规范电话为+后接8—15位数字、首位非0。姓名只去首尾空白，保留中间空格；邮编位数按站点国家判断，不按表的持有方判断。

题目	路径	候选函数	需要适配的部分
02	统一固定替代及边界修正	`fixed_value_repair.py` → `repair_fixed`	按已给合法范围设置参数，选择共同替代值；运行时长的有限超上界值可替代或修正到上界
02	共同参考分组中位数	`group_median_repair.py` → `repair_group_median`	接入`values`、`groups`、`reference`，使用框架预先提供的统一统计
03	原文模式扫描	`content_detection.py` → `detect_tokens`	联系信息的规则与格式边界

题目	路径	候选函数	需要适配的部分
03	规范化副本后扫描	`normalized_content_detection.py` → `detect_normalized_tokens`	规范化选项、适配扫描副本的规则与格式边界

TODO03的基础EMAIL规则仅覆盖本课的`.invalid`合成域；PHONE必做范围为带`+`区号、可能含括号、空白或连字符的号码。无需从零设计通用邮箱和全球电话验证，也不以扩展线索数量作为完成门槛。题旁注明候选函数及其模块；选用时在对应作答框内导入所选函数，再接入回调。

以上文件均在`可选算法/`。`field_classification.py`和`field_tags.py`已用于基础分级与标签整理，可结合源码查阅。

02-A和02-B各接入一条合格修复路径，03-A接入一条扫描路径；不要求把候选都实现，也不要求新增测试或性能对比。允许满足同一接口与公开约束的自写实现；选择依据直接写进报告并引用已有输出。

TODO01将规范后的结构化联系信息写入清洗表；TODO03的文本规范化只作用于备注扫描副本。NFKC和空白折叠可以覆盖部分全角或空白差异，但不能删除所有分隔符来拼接无关数字；命中仍是需要核实的线索，不直接等于字段分级。

回调提示

02-A/B都要返回接收`(values, groups, reference)`的函数；该函数返回与`values`索引及顺序一致的数值`Series`。`groups`在设备表中为型号、在案例表中为国家；`reference`是主流程已准备的对应参考。`repair_group_median`与此接口一致；`repair_fixed`的参数是`values, replacement, lower, upper, clip_above`，必须通过包装函数适配，不能直接把它作为三参数回调。03-A的扫描回调接收`(text, patterns)`并返回标签列表。

回调赋值使用函数名，例如`callback = format_book`；`format_book("海边")`会立即执行。需要补齐固定参数时，可在作答框内用普通函数包装，再把包装函数名交给框架；参数和返回值已匹配时直接使用原函数。

```
def decorate(text, prefix, suffix):
    return prefix + text + suffix

def format_book(title):
    return decorate(title, prefix="《", suffix="》")

callback = format_book
print(callback("海边"))
```

本课的字段分级

L1—L4为本课约定，级别越高，保护要求越高，并非直接引用法规的四级划分。

等级	含义	例子
L1	可公开的一般说明信息	项目说明、字段含义；业务表不必有L1字段

等级	含义	例子
L2	单独区分度有限、组合后可能定位对象的信息	型号、城市、案例日期
L3	需要限定用途的运行指标和业务结果	运行时长、告警次数、停机时长、故障标签
L4	可以直接标识或联系对象的信息	设备编号、姓名、邮箱、电话、详细地址

字段“类别”描述信息性质，例如联系信息或运行信息；“等级”表示本课要求的保护程度；“标签”补充扫描线索或复核提示，例如备注中可能出现邮箱。三者回答的问题不同，不能用命中一个标签直接替代全部分级判断。基础映射和备注复核逻辑已提供：`文本线索.csv`按案例记录扫描结果，`字段分级.csv`则按来源表及字段登记。任一备注尚未扫描时，整个`service_note`字段的分级保持未完成；全部备注已扫描且至少一条命中线索时，该字段统一按标识类L4记录依据；全部已扫描且均未命中时保留基础类别和等级，不表示每条备注都必然无风险。不为凑齐等级调整分类；任务2再结合用途决定必要输入和允许输出。

运行方式

在当前版本根目录（含根入口`main.py`、`utils.py`和`数据集/`的目录）运行：

```
python main.py --task 1
```

该命令只运行任务1，每次建立新的`runs/RUN-.../`，也可用`--output-dir 新目录`指定结果目录。先查看终端给出的本次路径和其中的`项目运行概览.md`，再打开任务1输出；修改代码后重新运行，避免把旧批次当作本次结果。要观察后续计算，运行`python main.py --task 3`、`python main.py --task 4`或完整入口`python main.py`，它们会在各自的新批次重跑必要前序。

生成文件怎么看

以下路径均相对于本次运行目录中的`01_数据资产盘点与质量治理/`。三张清洗表保留原表字段；其余证据表使用中文表头和状态。先从修改记录找到业务编号，再回查处理表和原始表。

文件	用途及每行含义	重点字段	支持的判断	阅读顺序
`质量处理.csv`	每行对应原始表中一条记录的一个修改或待复核项目；同一对象的修改与复核原因合并登记	来源表、记录编号、字段、原值、处理后值、处理方式、是否待复核、处理原因、复核原因	哪个值改了、为什么改；哪些问题仍保留或需要核实	1，先定位一处联系信息或邮编、一项时长问题
`清洗数据/cn_devices.csv`	华辰设备处理表；每行一台设备，已去除整行完全相同的重复记录	`device_id`、`operating_hours`、`temperature_c`、联系信息列、`site_country`、`site_postcode`	华辰记录当前保留的实际值，是否与质量记录对应	2，按质量记录中的设备编号回查

文件	用途及每行含义	重点字段	支持的判断	阅读顺序
清洗数据/de_devices.csv	德维设备处理表；每行一台设备，共同设备仍分别保留在双方表中	与华辰设备表相同，并用device_id核对共同设备	德维记录当前保留的值及共同设备的一致性，不能仅凭文件名认定治理完成	2，与华辰表及质量记录对照
清洗数据/service_cases.csv	服务案例处理表；每行一次案例，同设备可以有多条案例	case_id、device_id、downtime_hours、service_note、联系信息列、closed_date	案例停机、联系资料和关闭日期的处理结果；原备注与合法长停机是否保留	2，按案例编号回查
清洗对比.csv	每行比较一种来源、字段与统计口径下，当前处理和排除原始无效观测的均值	来源表、比较字段、当前处理均值、排除无效观测后的均值、当前方法样本数、排除无效值方法样本数、当前方法统计裁剪数量、排除无效值方法统计裁剪数量、统计贡献规则、下游用途	治理与排除异常的统计差别，以及差别是否伴随样本数或贡献裁剪变化	3，结合时长治理结果阅读
文本线索.csv	每行对应一条服务案例的备注扫描结果	来源表、记录编号、文本字段、内容线索、复核状态	是否实际扫描、命中哪些线索、是否需要复核；线索不等于已提取的联系方式	4，定位一条案例，再回查原备注
字段分级.csv	每行对应一张来源表的一个字段	来源表、字段、类别、等级、标签、判断依据	当前字段分级及其依据；备注扫描怎样影响service_note的整体分级	5，与文本线索对照
资产核对.csv	每行对应一张表，共三张表	资产编号、类型、持有方、内容线索、核对结论	字段分级是否齐备以及资料由谁持有；它不代替逐值质量检查	6，最后看汇总，异常再回查字段分级

先打开本次任务1输出目录中的质量处理.csv，按题目顺序查看一处联系信息或邮编的规范化、再查看一项非法时长的修复及待核实原因；再用文本线索.csv定位一条备注，并到字段分级.csv观察已提供逻辑如何使用扫描结果。

这些证据表使用中文表头和状态。用“来源表”“记录编号”“字段”定位，质量记录的“原始行号”是从0开始的数据行索引，不含CSV表头。备注线索只是匹配标签，不是提取出的联系方式；未扫描、扫描未命中和命中待复核须分别解释。

数值治理未完成时，原始问题保留在清洗表和质量证据中。德维设备运行时长不合格会使任务3研究处理等待，案例停机时长不合格会使任务3统计发布等待；任务4模型还会检查两方设备的必要数值。完成相应治理并重跑可解除质量等待，后续任务仍需完成自己的方法接入与规则检查，才能生成合格结果。

阅读清洗对比.csv时同时查看两种方法的样本数：排除原始异常会减少分母，均值差不能只解释为估计值的修正幅度；未完成治理时，“当前处理均值”也不表示质量检查已经通过。

合法长停机在清洗表保留原值，不按后续统计的72小时贡献上限清除。贡献裁剪的目的和统计口径见任务3《任务背景.md》的统计发布说明，质量修正与统计裁剪须分开解释。

在文本线索.csv中，“内容线索”为“尚未扫描”、“复核状态”为“尚未核对”，表示该条备注还没有完成扫描；已扫描未命中与命中后“需要复核”是不同状态。只要仍有备注未扫描，字段分级.csv中service_note的“类别”为“尚未分类”、“等级”为“尚未分级”；资产核对.csv也会保留相应的“尚未核对”。这些状态不能混写为同一种分级结论。

报告与提交要求

提交完成后的01_数据资产盘点与质量治理/任务文件夹和本任务报告。文件夹保留源码、算法及原有材料，并附报告引用的结果副本，注明原运行目录；具体提交方式见当前版本根目录的项目说明.md。

统一使用当前版本根目录的实验报告模板.docx撰写本任务报告。说明数值治理与文本扫描的选择依据和取舍，引用一处联系信息或邮编的前后变化、一项时长修复，以及一条备注线索及其分级结果，解释估计、格式检查或识别的局限。TODO01的四类处理均需完成；TODO03的邮箱、电话为必做，其他线索选做。无需逐字段重复解释，也无需另写自动盘点和已提供分级逻辑的实现说明。

本页说明本任务的基础要求；自主改进与成果展示要求统一见项目说明.md。