任务2：数据流转分析与使用决策

任务背景与目标

任务1提供了华辰与德维的设备处理表、服务案例处理表和字段分级记录，其中可能仍有待治理或待分级项。接下来，双方要商定合作中每个使用者能拿到什么。德维服务分析人员需要把同一设备的案例联系起来复核停机；研究组关心型号、区域和运行情况与故障的关系；服务管理人员只需要确认故障案例数，以及全部案例按约定裁剪贡献后的平均停机时长。这三种需要保留的数据能力不同，不能统一转交整张表。

合作还有两项目标：双方希望得到不重复计算设备的联合告警合计，并了解联合训练能否帮助预测未来故障。开展它们之前，必须知道哪些设备同时出现在双方数据中，所以“共同设备匹配”也单独登记为一个用途。

三项德维数据需求，加上设备匹配、联合告警统计和联合故障模型，形成六项用途。本任务先规定输入、输出和保护要求，任务3、4执行这些规则，任务5据此核验实际文件。

六项数据使用需求

用途	来源清洗表	使用者或后续步骤	要解决的问题	为什么不能直接给完整原表	后续任务
内部服务分析	`service_cases.csv`	德维服务分析人员	哪些案例属于同一设备，停机和故障情况怎样	需要案例关联，不需要联系信息和原设备标识	任务3
研究数据	`de_devices.csv`	研究组	型号、区域和运行情况与故障有何关系	精确地点、时长与标识可能形成识别线索，需要控制细节	任务3
服务统计	`service_cases.csv`	服务管理人员	确认故障案例有多少，全部案例的裁剪后平均停机多长	需要总体数字，不需要明细；还需限制单案例对统计的影响	任务3
共同设备匹配	`cn_devices.csv` 和 `de_devices.csv`	联合统计与训练步骤	哪些设备同时出现在双方数据中	匹配只需必要结果，不应输出双方完整编号表	任务4
联合告警统计	`cn_devices.csv` 和 `de_devices.csv`	双方合作分析人员	按约定贡献口径，告警合计是多少	共同设备不能重复计数，计算中间值与最终合计需分别考虑保护	任务4
联合故障模型	`cn_devices.csv` 和 `de_devices.csv`	合作模型组	联合训练能否帮助预测未来故障	最终需要共享模型参数，不需要把设备训练明细作为模型成果输出	任务4

输入与程序起点

读取同一次运行中，`01_数据资产盘点与质量治理/清洗数据/`下的`cn_devices.csv`、`de_devices.csv`、`service_cases.csv`，以及该任务输出目录中的`字段分级.csv`。这些清洗表可能仍含待治理问题，本任务不修复数值。

`choose_fields()`与`choose_protection_methods()`中已给出内部服务分析、服务统计、共同设备匹配三种完整配置；研究数据、联合告警统计、联合故障模型的字段配置待填，模型输出列已给定；保护方法只需补研究数据与联合告警统计，模型方法和理由已给出。04-D的来源字段与分级核对初始返回`None`，因此即使前三种用途配置已给定，**初次运行的六条规则仍全部未就绪**。`build_rules()`对每种用途的每个来源调用04-D，再由主流程保存检查结果。

按`main()` → `choose_fields()`的04-A—C → `choose_protection_methods()`的05-A/B → `check_input_fields()`的04-D → `build_rules()`阅读。本任务按资产名、字段名和用途名关联，不根据行位置作决策。

从使用需要推到输入与输出

输入字段是完成关联、计算或评价所需读取的字段；**允许输出字段**是接收方最终能拿到的内容。计算时需要某字段，不代表结果里也应保留它。

以已经给出的内部服务分析配置为例：要把同设备的多条案例联系起来，计算时需要设备编号；分析人员需要查看停机和故障确认，但不需要联系设备负责人。因此，先读取关联与分析所需字段，再用稳定假名替代原编号，结果只留下设备假名、停机时长和故障确认。稳定假名保留关联能力，移除原编号和联系方式控制结果披露。请用相同的推理顺序处理待填的三种用途，不要只照抄字段数量。

本课已给定结果应保留的能力和结构：研究结果保留型号、泛化区域、小时区间与真实故障标签，正式分组至少3条；服务统计保留两项受保护查询与口径，其中确认故障数统计案例，停机均值按全部案例为分母、每条贡献裁剪到[0,72]小时；匹配只输出共同令牌；联合告警每设备参与一次并输出受保护合计及口径；模型只输出参数。完整字段名及每行含义见任务3、4的结果表；研究输出名称已在04-A题旁列出，统计十列在`statistics`列表中提供，模型输出`parameter`、`value`已填在04-C中。

先明确规则、后执行处理，是为了让取数、生成结果和最终核验使用同一份依据。本任务配置字段、方法和理由，并核对来源字段及分级，无需在这里实现六套保护算法。

这些约定针对六类用途结果文件；质量报告、效用比较和过程证据保留在本地运行目录中，不属于对使用者开放的结果字段。

六类用途的保护家族受后续计算形式和输出约束限定，不能任意互换。服务统计示例已配置`DP`，其中Laplace或Gaussian的选择留到任务3；联合告警保留给定的设备级Laplace流程。方法家族与可选实现路线是不同层次。

需要完成的作答

TODO04【核心填空与接入】用途字段配置

在`choose_fields()`中，04-A配置`de_devices.csv`生成研究数据所需的输入与输出；04-B配置`cn_devices.csv`和`de_devices.csv`生成联合告警统计所需的输入与输出；04-C配置这两张设备表生成联合故障模型所需的输入，模型输出两列已给定。输入必须存在、已分级且足够完成计算；输出要符合既定结构和用途限制。计算中需要一个字段，不代表最终可以输出它。

04-D【来源核对】 `check_input_fields(data, catalog, asset, inputs)`的`data`是资产文件名到DataFrame的映射，`catalog`含`asset`、`field`、`level`等列，`asset`是当前来源文件名，`inputs`是该用途所选输入字段列表。核对当前来源资产的输入字段是否存在，并按资产名和字段名从分级目录筛出记录，判断覆盖完整且等级属于L1—L4。目录按资产和字段唯一登记，框架登记空配置和重复输入的问题；04-D也会收到空列表，不能因某个用途尚未填完就让整个任务报错；不要把其他资产的同名字段算进覆盖范围，也不要把L4直接理解为禁用。返回问题字符串列表；`[]`表示已核对无问题，`None`表示未作答，规则保持未就绪。该逻辑不执行保护算法、不修改来源。结合规则中的原因说明缺列、缺分级或无效等级为何不能就绪。

TODO05【核心填空与接入】保护决策

在`choose_protection_methods()`的“方法与理由”配置中，05-A为`de_devices.csv`的研究用途、05-B为两张设备表的联合告警统计用途选择合适的方法代号并解释原因；联合故障模型的FEDAVG配置与理由已提供。已提供的框架把规则接入任务3、4的取数和任务5的核查；实际保护操作在后续任务执行。两道题共6处作答框，不需要另写规则引擎。

方法参考与约束

可用方法代号

下表提供程序接受的接口名称及技术含义。请根据上方业务用途自行匹配，并解释选择依据；候选示例中的中性措施代号不能直接填入本项目。

代号	技术含义
`ANONYMIZED`	泛化组合线索并抑制小分组
`DP`	对有界统计贡献加噪，按声明预算发布
`FEDAVG`	本地训练后按样本量聚合模型参数；本身不等于参数加密或差分隐私
`PSEUDONYM`	以稳定假名替代标识，支持同用途关联
`PSI`	按给定令牌协议求交集
`SECURE_SUM_DP`	先保护求和过程，再对最终合计加噪
`NONE`	尚未选择，仅用于初始占位

代号必须准确填写；理由需要联系保留的业务能力、保护发生的位置及最终输出，不能只复述代号名称。稳定假名仍保留关联性，泛化与分组抑制也不保证消除所有识别风险。匹配、求和及联邦训练在同一工程中模拟各方步骤，不表示已经部署跨机构安全系统。

04-A/05-A对应研究数据，04-B/05-B对应联合告警统计，04-C填写联合故障模型的输入；模型方法与理由已提供。

方法示例

`可选算法/`的三个文件用独立小数据讲解思路，需迁移到本项目：

文件	可参考的思路
`input_field_selection.py`	区分关联依据、计算特征和评价标签，检查输入是否足够
`output_field_design.py`	根据接收方需要决定保留、转换或移除哪些内容
`protection_policy.py`	区分计算过程与最终输出需要的保护，解释方法边界

示例不会自动填写配置，也不执行任务3、4的保护操作。可以参考或复用，不另交示例作业。

运行方式

在当前版本根目录（含根入口`main.py`、`utils.py`和`数据集/`的目录）运行：

```
python main.py --task 2
```

该命令自动运行任务1、2，每次建立新的`runs/RUN-.../`，不会接着使用上一次单独运行任务1的目录。也可用`--output-dir 新目录`指定结果位置；以终端给出的路径和其中的`项目运行概览.md`为准。三张清洗表、字段分级和本任务规则都应取自这一批次。

若要单独查看字段选择方法示例，在当前版本根目录运行：

```
python 02_数据流转分析与使用决策/可选算法/input_field_selection.py
```

生成文件怎么看

以下文件位于本次运行目录中的`02_数据流转分析与使用决策/`。本任务只生成一张用途规则表；任务1输入和后续使用证据应沿同次运行目录回查。

文件	用途及每行含义	重点字段	支持的判断	阅读顺序
流转与保护规则.csv	共六行，每行登记一种用途的来源、输入、输出、方法及理由	结果名称、来源表、使用字段、允许输出字段、保护要求、规则已完成、理由	本次规则配置了什么、是否通过本任务配置检查、尚缺哪项；不能据此认定治理或保护已完成	1，先选一种用途对照需求；2，按来源回查任务1字段分级；3，后续运行后对照任务3、4结果登记或任务5检查

先打开本次运行中02_数据流转分析与使用决策/流转与保护规则.csv，对照一种用途回答“计算需要读什么、使用者最终拿到什么、理由是否对应需求”。表中“使用字段”按来源表保存字段列表，“允许输出字段”用|分隔，“保护要求”显示方法的中文名称。程序中的ready对应“规则已完成”列，True导出为“已完成且通过”。

ready=True表示当前字段列表、来源分级核对、方法代号及理由填写通过本任务的配置检查。所选方法须使用本页表格中除NONE以外的六种代号之一；拼写错误会提示并标为未就绪，NONE仍表示尚未作答。build_rules()不会自动证明输入是最小且足够的、输出符合用途约定、所选方法适用于该用途或理由论证正确。它也不表示时长问题已修复或保护方法已执行。任务3、4按规则取数，结果登记时核对实际方法及输出字段，任务5再结合实际文件核验。

规则未就绪时，后续取数保留完整字段的本地基线，并在结果登记中标明规则未完成；若计算所需数值仍非法，还会保留等待治理状态。规则就绪后才按“使用字段”取列。教学基线可能含原始标识或业务明细，不能把这些基线文件当作已满足用途约束的发布结果。

报告与提交要求

提交完成后的02_数据流转分析与使用决策/任务文件夹和本任务报告。文件夹保留源码、算法及原有材料，并附报告引用的结果副本，注明原运行目录；具体提交方式见当前版本根目录的项目说明.md。

统一使用当前版本根目录的实验报告模板.docx撰写本任务报告。选择两种用途比较输入、输出和保护决策，至少一种来自自主配置；引用一处后续实际取数、结果登记或检查中使用规则的证据。修改规则后，用python main.py --task 3、python main.py --task 4或完整入口python main.py重跑所需流程；命令会在新的批次执行必要前序。仅运行--task 2时，先完成两种用途的规则比较；后续使用证据要等任务3、4或5运行后补齐，并与同一批次的规则对应，再完成本任务报告。本阶段尚未生成下游文件，不等于程序失败。

本页说明本任务的基础要求；自主改进与成果展示要求统一见项目说明.md。