任务3：数据共享与安全发布

任务背景与目标

任务2负责为德维的三项数据需求确定输入、输出和保护规则，服务分析人员、研究组和服务管理人员需要依据这些规则取得各自可用的结果。直接交出清洗表仍会带出设备编号和联系信息；统一删除细节又可能让案例无法关联、研究无法分组。你的任务是从任务1的德维设备表与服务案例表出发，把既定规则落实为内部服务分析、研究数据和服务统计三份文件，分别保留所需能力，并用实际结果说明处理带来的代价。

为什么三份结果需要不同处理

内部分析使用稳定假名，让同一设备的多条案例仍能联系起来；研究数据把部分精确特征合并成较粗分组，并去掉过小的组；服务统计限制单条案例的贡献后加噪。框架已经提供比较、校验和保存，你只完成TODO06—08，并利用已有比较分析代价。

原始CSV和题目给定的输出约定应保持不变；任务1按要求治理清洗副本，本任务在用途副本上处理，不能为了通过检查修改真实故障标签或增加虚构记录。任务2的作答规则可以按题目要求调整，但调整后须重新运行相关前序和本任务，不能把新规则与旧结果混用。三份业务结果及处理证据供任务5核验；任务3与任务4是共同依赖任务1、2的两条分支，彼此没有前置依赖。这里的正式发布指在本地生成用途结果文件。

输入与程序起点

输入均来自同一次`runs/RUN-.../`运行：任务1的`01_数据资产盘点与质量治理/清洗数据/service_cases.csv`、同目录的`de_devices.csv`，以及任务2的`02_数据流转分析与使用决策/流转与保护规则.csv`。主流程分别为内部分析、研究数据、服务统计按各自规则取数：内部分析和统计使用服务案例，研究使用德维设备，两类案例用途的输入字段分别选择。案例表包含同一设备的多次独立案例，可按`device_id`分组、按`case_id`区分，再核对它们在内部分析结果中是否保留同一假名。

任务2某项规则的`ready`未为真时，该用途先读取完整清洗表作为基线输入；即使本任务已完成处理，登记也不会标为就绪。研究用途需要完成任务2的04-A、05-A，以及影响所有用途规则的04-D；已给定的内部分析、统计规则同样依赖04-D核对。规则就绪后才按所选字段取数，缺少实际计算所需字段会报错，保护代号或结果列与规则不一致会影响登记。

必要数值合格后，假名回调、匿名配置、统计机制或敏感度未完成时，程序保留本地基线；数值治理和作答完成是不同条件。

如果任务1还未修复运行时长中的缺失、非数值、非有限或越界值，匿名分组与效用比较记录`QUALITY_PENDING`（导出表显示“等待任务1数据治理”）；停机时长不合格时，停机均值留空、误差模拟和正式统计发布暂停，全部案例仍保留在公开分母中。空值表示尚未计算，不能解释为0或实测性能。补齐任务1数值治理后重新运行，相关流程才会继续检查配置与实现；假名化等不依赖这些数值计算的步骤仍可进行。比较、预算检查、发布参数适配与文件保存已提供；泛化和抑制调用由07-B完成，每道开放题只需选一条路线。

按main.py中的main() → TODO06—08 → 可选算法/阅读，作答区均在main.py。同目录的release_support.py提供匿名配置检查、共同评价样本比较，以及统计预算检查、误差模拟和正式发布。prepare_statistics()依次调用check_statistics_config()检查配置、compare_statistics_errors()比较本地误差、publish_statistics_result()正式发布；结果表与实际配置由main()保存并登记。需要追踪检查依据时，再阅读对应辅助函数。

需要完成的作答

TODO06：内部服务假名化

假名是原标识的替代表达。同一设备的多条案例必须得到同一假名，分析人员才能复核其停机；若每行随机改名，会破坏这种关联。用途域给令牌计算加入用途标记，使同一编号在不同用途下得到不同令牌，减少直接跨用途拼接。这里固定用带密钥的HMAC，32字符是本课内部分析输出的接口约定；假名仍支持关联，不等于已经匿名。

TODO06【核心填空与接入】内部服务假名化。 处理清洗后的service_cases.csv：在prepare_internal的06-A完成make_token回调，将device_id转换为稳定假名，保留对应案例的downtime_hours和confirmed_failure，生成内部服务分析.csv。公开协议固定为HMAC-SHA256，密钥为utils.py中的DEMO_TOKEN_KEY，用途域为INTERNAL_TOKEN_DOMAIN；消息是用途域:设备编号的UTF-8编码，取摘要前32个小写十六进制字符。输入编号和用途域，返回一个令牌字符串。06-A填写接收(device_id, domain)的可调用对象，不能填入一次调用得到的令牌。示例函数pseudonymize默认只输出16个字符，本题须显式适配为32个字符。四项检查与字段保留框架已提供；协议固定，包装写法可以不同。

DEMO_TOKEN_KEY是随课程代码公开的演示密钥，只用于复现本地协议；持有它的人能重算候选编号的令牌。四项检查验证本次输入的稳定性、用途隔离、令牌格式及碰撞、字段集合，不证明匿名，也不代替任务5对协议和来源记录的核验；假名检查通过还不代表停机数值治理完成。

TODO07：匿名化方案

研究组不需要设备编号，但型号、区域、精确时长等信息组合后仍可能缩小对象范围，这类组合线索称为“准标识符”。泛化是把细值换成较粗类别，例如把精确时长换成区间；整组抑制是移除记录数不足的整个组。用独立示意数据理解：若“型号甲、区域组一、同一小时区间”只有两条记录，而“型号乙、区域组一、同一区间”有四条，最低组规模取3时，前一组被移除，后一组保留。它展示组规模判断，不是本数据的实测结果。

k表示每个保留组合至少有多少条记录。本课正式方案要求k至少3，100或200小时是已给候选精度，不是统一安全标准或最优参数。扩大时长区间或合并区域可能保留更多记录，也可能损失细节；达到k仍不能排除组内故障标签同质性等风险，因此需要观察保留量与分析价值。

TODO07【选法与方案设计】匿名化方案。 处理清洗后的de_devices.csv：按device_model、由site_region映射的区域和operating_hours区间组织分组，保留真实failure_next_90d，生成研究数据.csv。在07-A填写selected_config字典，包含hours_width、k、region_groups；07-B按本轮参数完成泛化和整组抑制，可调用k_anonymity.py中的suppress_small_groups，返回实际保留表；用途依据和取舍直接写进报告。

可选路线	适配内容与取舍
100小时、k=3	保留较细时长分组，满足至少3条的正式组规模

可选路线	适配内容与取舍
200小时、k=3	时长信息更粗，可能减少小组抑制
100小时、k=5	要求更大的组，可能增加抑制
合法自选配置	合法正整数小时宽度、3到设备数之间的整数k，区域映射覆盖当前输入，键和值均为非空字符串；实现范围见“方法参考与约束”

这些是同一匿名算法下的不同方案。正式选择会自动加入实际`plans`，真实宽度、k和区域映射保存到`匿名化方案.json`供任务5重建；不能只改方案名称。各比较方案采用同一份所选区域映射。`K2_H100`只供比较，不能作为正式发布。

保留原索引与真实标签，不能造记录凑组。所有参与比较的方案共同保留记录至少20条，包含两类标签且每类至少2条。这是框架允许划分和计算评价指标的最低可用条件，不保证统计可靠或代表全部设备；框架会在训练前检查，不足时明确记录配置失败并提示调整。配置须按用途、精度和预先说明的规则选定，不能根据测试集AUC挑正式方案。必要运行时长合格后，未填写配置时，正式结果仍是本地原值基线；数值未治理时，`匿名化比较.csv`只记录等待状态，分组表和评价设备表为空。

07-B：让配置实际作用于研究数据

在`transform_research(devices, width, k, region_groups, quasi)`完成本轮区域映射、时长区间泛化和整组抑制。输入设备副本和本轮参数，输出保留原索引、全部原字段及其值，并新增`region_group`、`hours_band`的DataFrame；最终只发布四列的裁减由框架完成。不得写死正式方案参数。本轮比较可能使用k=2，正式方案仍要求k至少3。`quasi`为型号、泛化区域、时长区间；可选算法中的`suppress_small_groups`返回保留表和抑制报告，本题只返回保留表。

区间左闭右开，例如宽度100时150进入[100,200)，200进入[200,300)。保留所有达到本轮k的整组，不能只留下每组部分记录，也不能造行、换标签。`None`表示未作答，研究用途保留基线且不计算方案效用；实际空表表示该配置没有可发布记录，不能冒充未作答；按本轮规则抑制后确实为空时，比较流程会以配置检查失败登记，不进行效用评价。任一比较方案为空或共同样本不足都不能完成本轮研究发布。07-B返回值若违反整组保留、字段或来源对应约束，独立校验会抛出异常并中止本轮任务，修正后开始新的运行。

TODO08：统计发布

统计贡献、敏感度与预算的给定条件见下方同名专题。先按这些条件确定保护单位和贡献范围，再完成本题。

TODO08【选法与方案设计】统计发布。 处理清洗后的`service_cases.csv`：`case_id`用于识别案例，前提是任务1已去重并保持一案例一行；本题按行计数，不会根据`case_id`再次去重。用`confirmed_failure`统计确认故障的案例数，用`downtime_hours`计算有界贡献均值，生成`服务统计.csv`。在08-A选择整组`LAPLACE`或`GAUSSIAN`，08-B、08-C填写两项敏感度表达式，框架根据08-A自动选择对应发布函数；推导过程、机制选择和本次误差证据直接写进报告。

只在08-A选择机制，框架自动映射`laplace_release`或`gaussian_release`，负责三参数/四参数适配并核对函数身份与机制名，不需要重复填写函数对象。实际发布与误差模拟分别执行。正式发布使用系统随机源；误差模拟使用独立固定种子，不能把含真值的误差汇总结果当作对外发布。

必要停机数值合格后，机制选择或敏感度缺失时仍可运行精确统计基线；必要数值未治理时均值留空并等待，不能跳过缺失案例悄悄改变分母。已填非法配置则整组拒绝发布。框架同时检查三组模拟预算的尺度、试验值和误差聚合是否可用有限数表示；超出计算范围时保存参数失败与可读配置，不进行本次发布。两种机制的声明条件不同，不要求Gaussian比Laplace更准，也不要求不同运行产生完全相同的随机结果。

为什么比较匿名化后的分析效果

满足分组条件只说明结构约束成立，研究组还关心处理后的数据是否能分析故障关系。因此，框架用逻辑回归预测`failure_next_90d`并比较匿名方案的效用，无需另写训练。原始侧使用数值时长、型号和原区域；处理侧把型号、泛化区域和时长区间都作为类别特征。保留量表示还有多少设备可供分析；AUC表示模型将故障设备排在非故障设备前面的能力，通常越高代表这种排序越好，不等于预测正确率。

若两种方案分别在不同设备上评价，指标变化可能来自样本变了，而非仅来自泛化粗细。因此，框架取各比较方案共同保留的设备来评价，并固定种子510、按标签分层划分70%训练集和30%测试集；预处理只在训练集拟合。共同样本使对照更清楚，但也限制了结论覆盖范围；被所有方案共同保留的设备不能自动代表全部设备。

统计贡献、敏感度与预算

总体统计没有直接列出设备编号，但仍要考虑一条案例变化对输出的影响。差分隐私在明确的数据变化范围和预算下对统计值加噪；敏感度回答“只改变一个受保护单位，待发布的统计值最多变化多少”。先说清保护谁、怎么改变、贡献范围多大，才能推导噪声尺度，不能从机制名称猜数值。

本题保护单位是一条案例，每单位一行；“替换相邻”表示案例总数保持不变，只替换其中一条案例。计数把每条案例转成0或1；停机贡献先限制在0到72小时，均值仍除以公开的全部案例数，而非仅除以故障案例数。同一设备可有多条案例，本题保护的是单案例贡献，不是整台设备的全部案例。72是本课给定的贡献边界，目的在于限制单案例影响，既不是由数据最大值推算的，也不是合法停机的清洗上限。例如，真实停机超过72小时的案例在任务1保留原值，只在本统计中按上限贡献。请据此自行推导两项敏感度表达式。

可选路线	自动调用函数	已提供的每查询预算
Laplace	`laplace_release`	epsilon=0.5，delta=0
Gaussian	`gaussian_release`	epsilon=0.5，delta=5e-6

上表的epsilon、delta是本课给定预算：epsilon描述隐私损失约束，delta是Gaussian路线声明中允许的松弛项；这些数值不代表已经过行业风险评估的安全标准。敏感度须按前述口径推导，使用本次实际公开案例数，不硬编码案例数，不因选择Gaussian而省略贡献边界。总epsilon不超过1、总delta不超过`1e-5`；本轮不混搭两种机制。Gaussian使用给定公式的`0<epsilon<=1`条件。

方法参考与约束

自选`hours_width`须在int64可表示的正整数范围内，即不超过9223372036854775807；这是避免数值表示溢出的实现边界，不是业务上推荐的小时宽度。使用已给候选通常无需研究此极限；配置失败时结合原因核对宽度、区域映射和共同样本。

可选算法/中的hmac_pseudonymization.py对应06，k_anonymity.py对应07，laplace_mechanism.py与gaussian_mechanism.py是08的两条路线；utility_evaluation.py已用于匿名化比较。06按题旁模块提示在作答框内导入所选函数；需要适配参数时可参考任务1《任务背景.md》的“方法参考与约束”中的回调说明，08的实际发布函数由机制选择自动确定。

其余示例用于比较方法边界：AES示例支持持钥解密；本目录提供的SHA256标识散列示例没有密钥，也未接入用途域；随机响应处理回答侧扰动，归一化只调整尺度。它们不能直接替代本任务的既定输出流程。

运行方式

在当前版本根目录（含根入口main.py、utils.py和数据集/的目录）运行：

```
python main.py --task 3
```

根入口会建立新的运行目录，依次执行任务1、2、3，不复用旧运行中的清洗表或规则。--task 3不会执行任务4、5；需要最终核验时运行python main.py --task 5，该命令会新建一轮运行并执行全部前序。

本次任务输出目录为runs/RUN-.../03_数据共享与安全发布/。三份业务结果（内部服务分析.csv、研究数据.csv、服务统计.csv）保存在其结果文件/子目录；检查、比较、方案参数和结果登记文件直接保存在任务输出目录中。

生成文件怎么看

本节未另行注明的路径，均相对于本次runs/RUN-.../03_数据共享与安全发布/。先看导航和登记，再根据自己的判断选择相应结果与证据。

文件	用途及每行含义	重点字段	支持的判断	阅读顺序
结果登记.csv	每份已登记业务结果一行，保存处理配置和来源摘要	“结果名称”“实际方法”“阶段检查”“处理说明”“实际保护配置”“输入文件及摘要”“规则摘要”	本次结果是否在生成阶段就绪、用了哪些输入和规则；不等于任务5已独立核验通过	1：核对生成依据
结果文件/内部服务分析.csv	每个服务案例一行，保留同设备案例关联	device_token、downtime_hours、confirmed_failure，完成后只有这三列	同设备案例仍可关联，停机和故障标签仍可分析；不能据此认定匿名	2：看内部分析结果
假名检查.csv	每项实际假名检查一行	“检查项”“检查结论”“原因”	本次输入是否满足稳定性、用途隔离、令牌格式及碰撞、字段集合要求	3：解释内部结果
结果文件/研究数据.csv	每个保留设备一行，提供泛化后的研究字段	device_model、region_group、hours_band、failure_next_90d，完成后只有这四列且不输出设备编号	正式研究结果保留了哪些分析信息	4：看研究结果

文件	用途及每行含义	重点字段	支持的判断	阅读顺序
匿名化方案.json	一个对象保存本次采用的匿名化配置，也可能是框架比较基线；等待治理或配置无效时为null	hours_width、k、region_groups	实际采用的小时宽度、最低组规模和区域映射；须结合登记判断是否正式选择，完成后供任务5重建	5：确认正式方案
匿名分组.csv	正式结果的每个准标识符组合一行	“设备型号”“泛化区域”“小时区间”“组内记录数”“标签种类数”	各组是否达到本次k，以及是否出现标签单一的组；达到k不排除所有披露风险	6：检查研究分组
匿名化比较.csv	每个匿名化候选或基线一行；等待或失败时记录对应状态	“方案”“保留记录数”“抑制记录数”“最小组规模”“共同评价设备数”“原始AUC”“处理后AUC”“实现状态”	在共同评价样本上，保留量和模型排序能力如何变化；先看状态再解读指标	7：解释匿名化代价
评价样本.csv	每个共同评价设备一行	“设备编号”	哪些设备进入共同评价范围；不直接标明训练/测试划分，也不是对外研究数据	8：按需追查样本
结果文件/服务统计.csv	确认故障案例数、裁剪贡献后的平均停机各一行	query、released_value、mechanism、epsilon、delta、privacy_unit、adjacency、public_n、contribution_limit、records_per_unit，完成后为这十列	本次正式发布的统计值、机制、预算和保护单位；带噪值不是精确真值	9：看统计结果
统计误差.csv	所选机制下，每组预算的每项查询一行	“发布机制”“统计查询”“总预算”“本查询预算”“本查询delta”“试验次数”“课堂真值”“平均绝对误差”“误差目标”“实现状态”	本地模拟中的加噪误差随预算怎样变化；不是本次正式发布的单次误差	10：解释统计可用性

上表列出了完成后的业务字段合同。基线文件可能含原始字段或精确统计，不能当成完成后的用途结果；统计真值、评价设备编号与比较证据属于本地核对材料，不属于三份用途结果。mean_downtime的真值是每条贡献裁剪到[0,72]后的均值，不是清洗表原停机时长的均值。带噪输出未额外取整或裁剪，计数可能为小数，噪声较大时也可能超出自然范围；不要直接当成精确案例数。

先读本次运行目录的项目运行概览.md和结果索引.csv（通用读法见项目说明.md），区分已保存、普通基线、等待治理、检查失败或未生成结果。再读本任务结果登记.csv中的“阶段检查”和“处理说明”：该表没有独立的状态列，“阶段检查”通过表示生成阶段就绪，不等于任务5独立核验通过。针对自己的判断查证据：需要确认案例关联是否保留，就看假名检查.csv；需要解释研究精度的代价，就看匿名化比较.csv；需要讨论统计可用性，就看统计误差.csv。其余文件用于追查具体原因。

统计配置通过后，统计误差.csv记录所选机制在总epsilon为0.2、0.5、1.0三组预算下的模拟，每项查询分得一半，每组每查询重复200次；Gaussian的每查询delta保持5e-6。正式发布使用总epsilon=1的配置。表中“平均绝对误差”相对于裁剪后的查询真值计算，只衡量加噪误差，不包含裁剪对原始均值的影响，也不是本次正式发布值的单次误差。

平均绝对误差目标为计数5例、均值1小时，用于讨论实用性，不作为机制正确性的统一门槛，也不保证每次随机发布都达标。各预算模拟对同一查询复用固定种子，便于控制随机因素；它们不是三轮对外发布。正式重复发布则需考虑累计预算。未完成或配置预检查失败时不开展模拟；模拟中发生数值失败时，整组试验成绩被清空并记录失败。统计配置和来源见`结果登记.csv`。

若报错中止，部分文件可能尚未生成；查看本次运行目录的`运行日志/03_数据共享与安全发布.log`和`错误日志.txt`，按异常原因修正后开始新运行，不要拿旧目录补齐。

报告与提交要求

提交完成后的`03_数据共享与安全发布/`任务文件夹和本任务报告。文件夹保留源码、算法及原有材料，并附报告引用的结果副本与原运行目录；具体提交方式见当前版本根目录的`项目说明.md`。

`compare_research_plans`的比较代码已提供，在报告中写明本次运行目录、所选匿名方案名、至少两项实际指标和解释。联系组规模、保留量及分析效用，解释为什么各方案使用共同评价样本。评价内部先按稳定设备编号组织共同记录，再固定种子拆分，始终保留来源索引与真实标签，不排序回写原CSV；在设备集合与数值不变时，仅重新排列输入行不会改变拆分成员。清洗方法改变数值或抑制改变共同样本后，指标可以改变。引用07题实际正式选择，可与一个已有候选比较；不要求AUC下降，也不要求额外调参。

统一使用当前版本根目录的`实验报告模板.docx`撰写本任务报告。说明假名用途及边界、一个正式匿名方案和一种发布机制，给出两项敏感度推导及预算依据；引用本次匿名化比较中至少两项指标，解释共同评价样本的作用，并引用一项统计误差证据。无需实现未选机制或额外调参。

本页规定本任务的基础要求；自主改进与成果展示按`项目说明.md`执行。